Bioinformatica

Trabajo Práctico Final

Alumnos

Tylson, Emilio - 54022 Gutierrez, Ignacio - 54293

Profesor

Yankilevich, Patricio

Indice

_			- 4
-	rC		-1
_		U	

Ejercicio 2

Ejercicio 3

Ejercicio 4

Ejercicio 5

Ejercicio 6

Pregunta A

Pregunta B

Pregunta C

Pregunta D

Pregunta E

Pregunta F

Pregunta G

El trabajo se decide en enfocar en la Apolipoproteína E, proteína relacionada con el Alzehimer (https://www.ncbi.nlm.nih.gov/nuccore/NM_001302688.1?report=genbank). El código toma el archivo genbank del ARN mensajero en formato genbank, y realiza la transcripción de la proteína mediante los 6 posibles marcos de lectura (orf).

De todos los marcos de lecturas realizados, el orf 0 es el que genera la proteína con menos caracteres de finalización intermedios (sólo posee estos al final de la secuencia). Por lo que se estima que este marco de lectura sería el correcto. No obstante en el siguiente ejercicio donde se realizará el BLAST frente a una base de datos de proteínas, se podrá estimar de mejor manera cuál es el marco de lectura correcto.

Ejecución:

\$ perl Ex1.pl [path archivo Genbank]

Ejercicio 2

El código realiza BLAST sobre Apolipoprotein E de forma local o remota. Básicamente entra como input el archivo en formato fasta de la proteína, y genera un blast report en el a carpeta ../data/exercise2_out.

Como conclusión se puede observar que de todos los BLAST hechos, el del marco de lectura 0 es el genera más matches. De hecho todas las proteínas con las que se está alineando son distintas variaciones de la Apolipoproteína E en distintas especies. Por ejemplo la segunda proteína con más score de coincidencia es la Q9GLM7 que pertenece a la especie del orangután, o la tercera (Q9GLM8) es la Apolipoproteína E de los gorilas.

Ejecución:

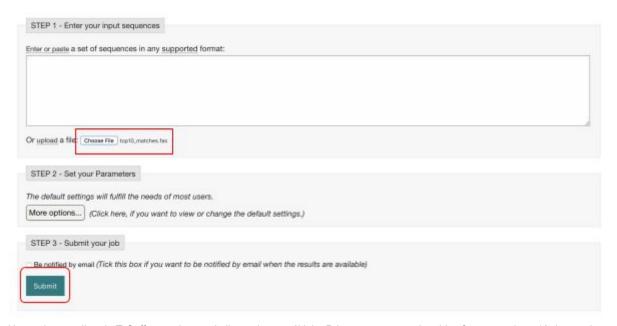
\$ perl Ex2.pl [path al fasta input] [path al reporte BLAST] [1 para remoto | 0 para local]

El código toma como input el archivo blast generado en el ejercicio 2. Luego, toma el nombre de las primeras 10 secuencias con mayor score en el alineamiento. Además busca la correspondiente secuencias en la base de datos swissprot y las escribe en un archivo fasta, en el que también está presente la Apolipoproteína E, nuestra proteína de referencia.

Ejecución:

\$ perl Ex3.pl [path al blast report] [path al archivo fasta de la proteína referencia]

De la página https://www.ebi.ac.uk/Tools/msa/ que ofrece diferentes alternativas para realizar el secuenciamiento, usamos T-Coffe. En dicha aplicación subimos el archivo generado por el código anterior, el cual genera un archivo fasta con las 10 secuencia con más similitud obtenidas por BLAST sobre Apolipoproteina E del homosapiens. La alineación genera un archivo que está subido en ../data/exercise3 out/msa.out.



Herramienta online de T-Coffe para hacer el alineamiento múltiple. Primero s e carga el archivo fasta con el top 10 de matches generado por el código. Luego apretando "submit" realiza el alineamiento.

Se puede observar en el alineamiento, que los primeros aminoácidos no matchean pero luego en la cadena principal de aminoácidos existe una coincidencia de uno a uno en todas las especies, por lo que se podría concluir que sería la estructura principal de la proteína, que le da la funcionalidad principal.

A0A0D9S1R0.1 NM_001302688 P02649.1 P0DKU9.1 P0DKY2.1 P0D094.1 P0D095.1 Q9GJU3.1 Q9GLM6.1 Q9GLM7.1 Q9GLM8.1	GTGGALLDKSGILESYSAPAEVKDVLPQEPVRSAVGGTGMSSGASRKSWD
4040000100 1	MICH MAALL VITEL ACCOMMEDIUM DETERMINED
A0A0D9S1R0.1 NM 001302688	MKVLWAALLVTFLAGCQAKVEQPVEPETEPELRPQ PGNPWPPDWPITGRKMKVLWAALLVTFLAGCQAKVEQAVETEPEPELROO
P02649.1	MKVLWAALLVTFLAGCQAKVEQAVETEPEPELRQQ
P0DKU9.1	MKVLWAALLVTFLAGCOAKVEOPVESEPEPELROO
P0DKY2.1	MKVLWAALLVTFLAGCOAKVEOPVEPETEPELROO
P0D094.1	MKVLWAALLVTFLAGCOAKVEOPVEPETEPELROO
P0D095.1	MKVLWAALLVTFLAGCQAKVEQPVESEPEPELRQQ
Q9GJU3.1	MKVLWAALLVTFLAGCQAKVEQVVETEPEPELHQQ
Q9GLM6.1	MKVLWAALLVTFLAGCQAKVEQAVEPEPEPELRQQ
Q9GLM7.1	MKVLWAALLVTFLAGCQAKVEQVVETEPEPELRQQ
Q9GLM8.1	MKVLWAALLVTFLAGCQAKVEQAVETEPEPELHQQ

A0A0D9S1R0.1	TEWOSGOPWELALGRFWDYLRWVOTLSEOVOEELLSPOVTOELTTLMDET
NM_001302688	TEWQSGQRWELALGRFWDYLRWVQTLSEQVQEELLSSQVTQELRALMDET
P02649.1	TEWQSGQRWELALGRFWDYLRWVQTLSEQVQEELLSSQVTQELRALMDET
P0DKU9.1	TEWQSGQPWELALGRFWDYLRWVQTLSEQVQEELLSSQVTQELTTLMDET
P0DKY2.1	AEWQSGQPWELALGRFWDYLRWVQTLSEQVQEELLSPQVTQELTTLMDET
P0D094.1	AEGQSGQPWELALGRFWDYLRWVQTLSEQVQEELLSPQVTQELTTLMDET
P0D095.1	TEWQSGQPWELALGRFWDYLRWVQTLSEQVQEELLSSQVTQELTTLMDET
Q9GJU3.1	AEWQSGQRWELALGHFWDYLRWVQTLSEQVQEELLSSQVTQELTALMDET
Q9GLM6.1	AEWQSGQPWELALGRFWDYLRWVQTLSEQVQEELLSSQVTQELTALMDET
Q9GLM7.1	AEWQSGQRWELALGRFWDYLRWVQTLSEQVQEELLSSQVTQELTALMDET
Q9GLM8.1	AEWQSGQRWELALGRFWDYLRWVQTLSEQVQEELLSSQVTQELTALMDET
	* **** *******************************

Captura del archivo de salida de la alineación múltiple

El código busca el nombre de cada proteína incluida en el BLAST report, cuya descripción contenga el pattern ingresado como input. Luego por cada proteína se busca la secuencia en la base de datos swissprot. Luego cada secuencia es escrita en un archivo fasta con el nombre que es ingresado por parámetro. A su vez por cada match del pattern se escribe en un archivo paralelo el ACCESSION que indica la proteína, su descripción y el índice de la descripción donde hubo match del pattern. Ambos archivos de salida se crean en ./data/exercise4_output .

Ejecución:

\$ perl Ex4.pl [path al BLAST report] [pattern] [nombre del fasta de salida]

El siguiente ejercicio se realizó en python debido a que los wrappers de Bioperl tenían problemas para ser instalados. El primer paso que realiza el código es utilizar la función **getorf** de EMBOSS el cual escribe la salida en ./data/exercise5_out/out.orf . El programa **getorf** encuentra y extrae los posibles marcos de lectura (orf) de la secuencia de aminoácidos ingresada, en este caso el de la Apolipoproteína E, marcando los codones de START y de STOP.

Luego el código ejecuta *patmatmotifs* de EMBOSS y escribe su salida en ./data/exercise5_out/out.patmatmotifs . El program lee una secuencia de proteínas y la busca en la base de datos prosite. Escribe un reporte EMBOSS donde detalla la locación y el score de los matches.

_		 ,
⊢	ואמו	۱n:
_	iecι	<i>ו</i> ו.

\$	D١	∕th	on	Ex5.	Ŋ۱
Ψ	М 1	,	\circ	_^~	м,

Ejercicio 6

Pregunta A

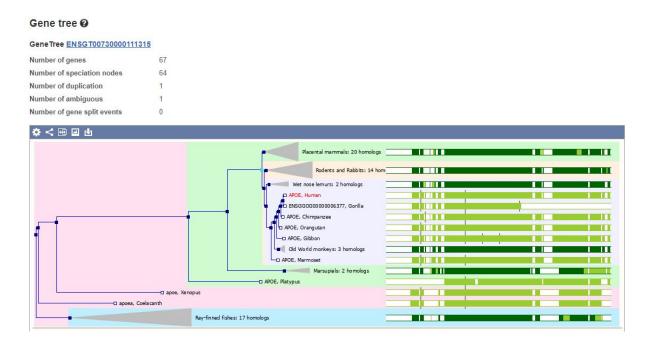
A partir del gen o proteína de interés para ustedes dar su link a NCBI-Gene como una entrada de Entrez. Expliquen brevemente lo que hace la proteína y porque la eligieron.

La apolipoproteína E (APOE) es una proteína con 299 aminoácidos de largo y transporta lipoproteínas, vitaminas liposolubles y colesterol hacia el sistema linfático y luego a la sangre. Es sintetizada principalmente en el hígado, aunque se ha encontrado también en otros tejidos, como el cerebro, riñón y el bazo. El gen que la sintetiza se encuentra en el cromosoma 19 y el mismo tiene 3 alelos principales. La presencia de uno de estos 3 alelos está asociado a una mayor probabilidad de contraer la enfermedad de Alzheimer. Es una proteína de baja densidad, responsable de remover el colesterol del flujo sanguíneo y transportar triglicéridos a los tejidos. Variaciones en APOE está relacionada con el metabolismo del colesterol, que incrementa las chances de ataques cardíacos.

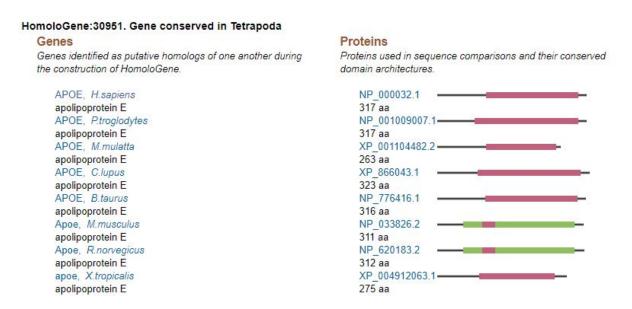
Pregunta B

Cuantos genes/proteínas homólogas se conocen en otros organismos? Utilicen la información que está en la base de datos de HomoloGene y en la base de datos Ensembl. Describan los resultados en ambas bases de datos y en qué se diferencian.

Mencionen sobre que tan comun creen son estos genes o proteínas y a que grupos taxonómicos pertenecen (solo en las bacterias, en los vertebrados, etc).



En el árbol genético del gen APOE (en Ensembl) podemos apreciar en rojo el gen humano y luego otros genes homólogos (67 en total) presentes en otras especies, todas vertebrados.

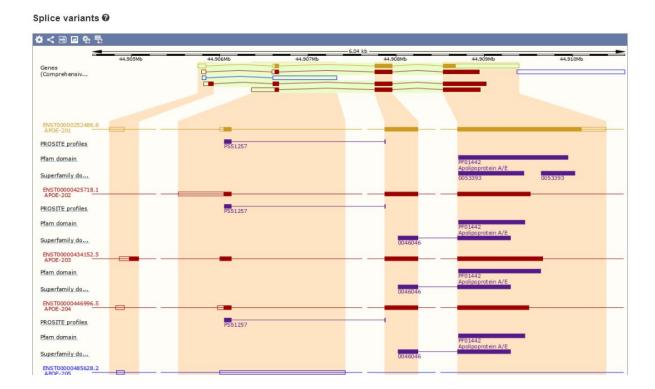


En HomoloGene podemos apreciar las especies en las que se encuentran los homólogos, aunque no la cantidad exacta de genes.

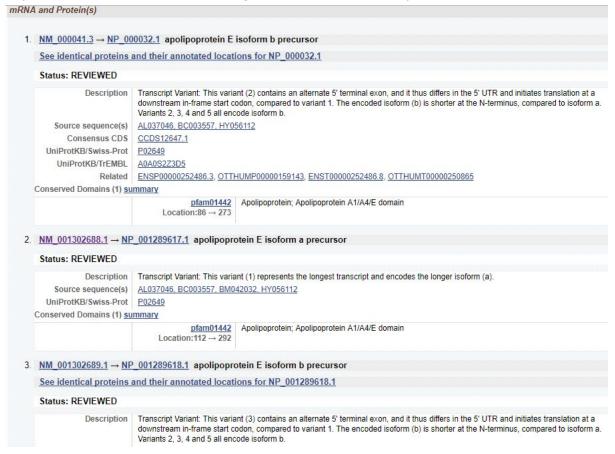
Pregunta C

Cuantos transcritos y cuantas formas alternativas de splicing son conocidos para este gen/proteína? Cuales de estos splicing alternativos se expresan? Tienen funciones alternativas? Buscar evidencia de esto en las bases de datos de NCBI y en los transcriptos de Ensembl. Como es el número de splicings alternativos diferente entre las dos bases de datos y cual piensan que es más precisa y porque?

En Ensembl encontramos 5 formas alternativas de splicing, aunque no tenemos mucha información de cada una.



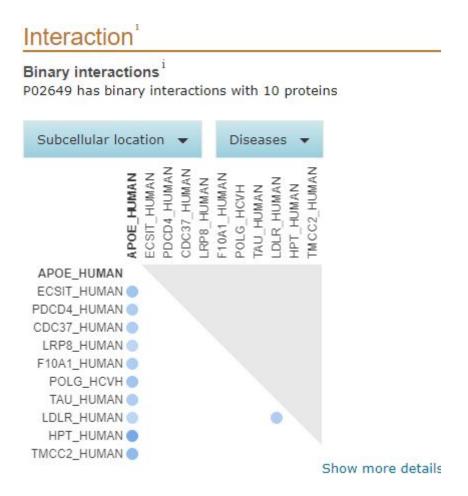
En NCBI encontramos la misma cantidad de formas alternativas de splicing, pero nos da más datos. Nos dice que existen 2 isoformas de la Apolipoproteina E (isoforma A e isoforma B) y que 4 de las variantes de splicing codifican la isoforma B y la otra la isoforma A.



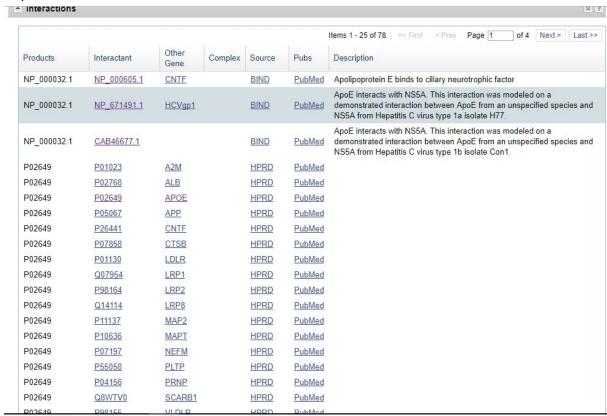
Pregunta D

Con cuantas otras proteínas interactúan el producto génico de su gen? Existe un patrón o relación entre las interacciones? Mencione las interacciones interesantes o inusuales. Usted encontrará las interacciones de su gen/proteína tanto en la base de datos NCBI Gene como en la base de datos UniProt. Compare las dos tablas entre si. Hay proteínas que interactúan unicas para cada tabla?

En UniProt vemos que interactúa con 10 proteínas. En particular interactúa con el receptor de lipoproteínas de baja densidad y la proteína TAU, la cual tiene un vínculo fuerte con la enfermedad del Alzheimer.



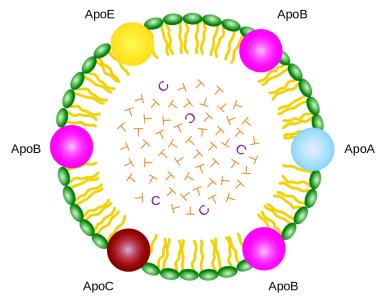
En NCBI vemos que existen 78 interacciones con el gen. En particular menciona una interacción con la proteína NS5A, proteína que juega un rol esencial en el desarrollo de Hepatitis C.



Pregunta E

Expliquen brevemente de qué componente celular forma parte su proteína (pista: se puede estudiar la información de Gene Ontology - GO). A qué procesos biológicos pertenece (pista idem)? En qué función molecular trabaja esta proteína? Los términos ontológicos de genes los pueden encontrar en NCBI Gene, en la base de datos UniProt y haciendo una búsqueda en AmiGO.

La Apolipoproteína E (APOE) es un componente de la proteína de los Quilomicrones, lipoproteína más compleja localizada en el epitelio del intestino y se encarga de transportar y catabolizar por el sistema linfático los los triglicéridos, los fosfolípidos y el colesterol ingeridos. En este caso APOE es el receptor encargado de metabolizar y transportar las lipoproteínas ricas en triglicéridos que son de baja densidad.



APOE es una molécula que compone a los Quilomicrones, una proteína de mayor complejidad

APOE que forma parte de la estructura más compleja de lo Quilomicrones, forma parte de la ruta exógena de transporte de lípidos al hígado, cerebro o riñón:

- 1 Los triglicéridos son captados en el intestino delgado.
- 2- Luego desplazarse por el sistema linfático las proteínas APOE y APO CII son agregadas, formando la estructura del Quilomicrón.
- 3- Luego, esta molécula se transporta por sangre hasta los tejidos periféricos como los músculos y los tejidos adiposos, donde el Quilomicrón se degrada, y los ácidos grasos se usan como fuente de energía de las células.

Analizando su funcionamiento a un nivel molecular, se pudo encontrar realizando búsquedas en la base de datos AmiGO2 que la APOE se encarga de diversas funciones:

Unión con Beta-amiloide:

Interacción selectiva y no covalente con el péptido Beta-amiloide y sus precursores. Este péptido de 36 a 43 aminoácidos, está fuertemente relacionada con la enfermedad del Alzheimer a pesar de que se encarga de otras diversas funciones como activación de quinasas, la protección contra estrés oxidativo, regulación del transporte de Colesterol actuando como un factor de transcripción y actividad antimicrobiana (especialmente asociado con su acción pro-inflamatoria).

Actividad molecular estructural:
 Contribuye a la integridad de la estructura de los Quilomicrones

Transporte de lípidos:

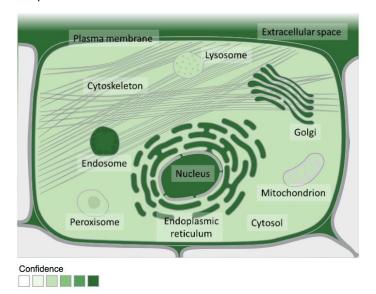
Permite el movimiento directo de los lípidos entre células.

Unión proteica:

Interaccion selectiva y no covalente con los triglicéridos.

Unión con fosfolípidos:
 Interacción selectiva y no-covalente con los fosfolípidos, una clase de lípidos que contienen ácido fosfórico y forman parte de la membrana celular

La proteína APOE puede encontrarse en diversas partes de la célula, pero como su función es mayormente de captación de triglicérido, ésta se encuentra mayormente en sectores extracelulares y en su membrana. Otro lugares en donde se puede localizar, una vez que se está transportando el lípido es en ene el núcleo , el aparato de golgi o en el retículo endoplasmático.



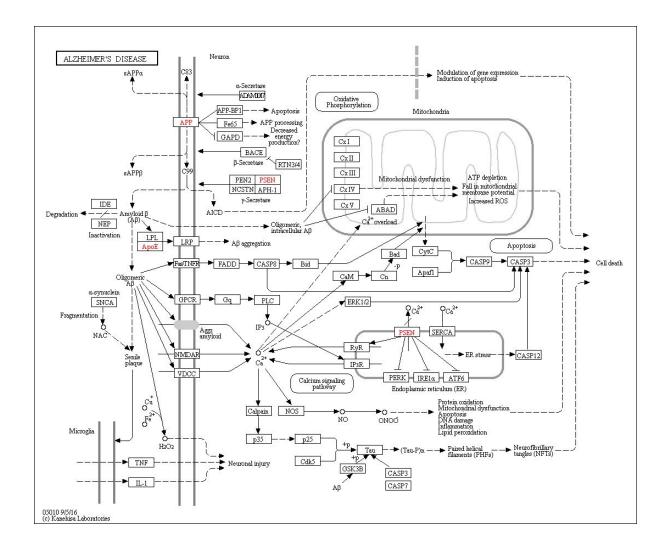
Compartment	Confidence	
plasma membrane	5	
extracellular	5	
nucleus	5	
endoplasmic reticulum	5	
golgi apparatus	5	
endosome	5	
cytoskeleton	2	
mitochondrion	2	
peroxisome	2	
cytosol	2	
lysosome	2	

Distintos niveles de confianza en la locación de la proteína APOE

Pregunta F

Discutan brevemente en qué estructura o vías metabólicas específicas (pathways) estaría participando su gen/proteína (Reactome, KEGG son algunas bases de datos de pathways).

En una primera instancia se utilizó la Kyoto Encyclopedia of Genes and Genomes (KEGG) para averiguar el pathway de la Apolipoproteína E. En esta base de datos se muestran datos sobre el funcionamiento a alto nivel de los sistemas biológicos. El pathway que figura se en esta página está relacionado con la enfermedad del Alzheimer. El pathway se presenta con el siguiente mapa donde se resalta en rojo la principales proteínas que interactúan en la enfermedad del Alzheimer.



Esta enfermedad, es un desorden crónico que destruye las neuronas causando serios trastornos cognitivos. Se asocia con las placas seniles y los ovillos neurofibrilares, que son depósitos extracelulares de beta-amiloide en la sustancia gris del cerebro y que se asocian con la degeneración de las estructuras neuronales, así como una abundancia en microglía y de astrocitos. Los beta-amiloide (Abeta), perteneciente a las placas seniles, tiene varios efectos patógenos en células y en las organelas. Los Abeta activan a las enzimas Caspasa que se encargan de la muerte celular programada. Alternativamente, la parte intracelular de Abeta contribuye a la patología ayudando al proceso del hyper-fosforilación (mecanismo de la regulación de la mitosis), terminando el funcionamiento de las mitocondrias y produciendo disfunción de calcio, degradando las estructuras neuronales. Estudios revelaron cuatro genes que están relacionados con esta enfermedad. Estos genes son: proteína amiloidea precursora (APP), presenilina 1 (PS1) y 2 (PS2) y la Apolipoproteína E (APOE). Por lo que mutaciones asociadas a sus genes pueden producir un aumento de la producción de los péptidos Abeta y la interacción con estos

Pregunta G

Entrar en la base de datos de variantes genéticas de SNP e intentar interpretarlo encontrar info sobre alguna variante (reference SNP-rsXXXX) asociada con la patología investigada en su gen de interés. Que variante es? Hay información sobre la frecuencia que tiene esta variante en la población? Que grupo étnico parece ser el mas afectado?

Existen tres variantes comunes, o isoformas de APOE que están definidos por dos SNPs, el rs429358 y el rs7412, nombrados como APOE-ε2, APOE-ε3 y APOE-ε4. Las proteínas generadas por los genes se llaman respectivamente APOE2, APOE3 y APOE4. Siendo APOE3 la variante estándar de la proteína, por lo que la gente hereda APOE-ε3 mas otras variantes de cada padre.

A pesar de que estos son las variantes más comunes, existen otras combinación de nucleótidos por lo que se pueden formar subtipos

rs429358	rs7412	Name
С	Т	ε1
Т	Т	ε2
Т	С	ε3
С	С	ε4

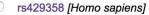
Combinación de nucleótidos para formar cada subclase del gen

Se estudió que las personas que poseen la variante APOE-ε4 mas cierto SNPS en otras partes del genoma, tiene mayor riesgo de desarrollar la enfermedad del Alzheimer. Estas otras variantes son:

- Rs2373115 en GAB2
- Heredar el alelo rs1799724 (T), aparentemente incrementa el riesgo de Alzheimer en APOE-ε4 y está asociado con alteraciones los niveles de concentración Abeta42
- Una variación de POLD1, más la presencia de APOE-ε4, dobla las probabilidades de la enfermedad.

Más en detalle, el alelo rs429358 es un SNP localizado en el cuarto exón de APOE, y afecta al a la posición 130 de la proteína resultante. Como se puede ver en el cuadro anterior, la variación más común del alelo es en nucleótido (T) , y combinado con el SNP rs7412 (C) forman el APOE-ε4. Como se dijo anteriormente, APOE-ε4 está fuertemente relacionado con el riesgo de tener Alzheimer. Sin embargo mucho estudios

estimaron que el nivel de riesgo dependen de la edad, sezo y varios factores. Heredando dos pares (homozygous) de rs429358 (C) o heredando (C;T) incrementan fuertemente las chances de la enfermedad.



1.

GCTGGGCGCGGACATGGAGGACGTG[C/T]GCGGCCGCCTGGTGCAGTACCGCGG

Chromosome: 19:44908684
Gene: APOE (GeneView)

Functional Consequence: missense

Allele Origin: T(germline)/C(germline)

Clinical significance: Pathogenic

Validated: by 1000G,by 2hit 2allele,by cluster,by frequency,by hapmap

Global MAF: C=0.1506/754

HGVS: NC_000019.10:g.44908684T>C, NC_000019.9:g.45411941T>C, NG_007084.2:g.7903T>C,

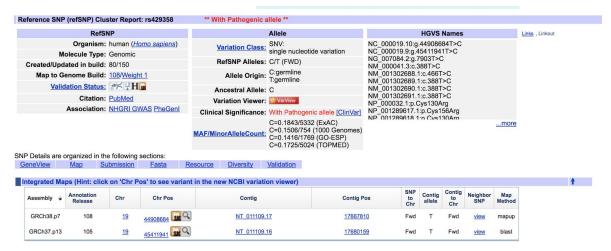
NM_000041.3:c.388T>C, NM_001302688.1:c.466T>C, NM_001302689.1:c.388T>C, NM_001302690.1:c.388T>C, NM_001302691.1:c.388T>C, NP_000032.1:p.Cys130Arg,

NP_001289617.1:p.Cys156Arg, NP_001289618.1:p.Cys130Arg, NP_001289619.1:p.Cys130Arg, NP_001289620.1:p.Cys130Arg,

XM_005258867.1:c.466T>C, XM_005258868.1:c.388T>C, XP_005258924.1:p.Cys156Arg,

XP_005258925.1:p.Cys130Arg

PubMed Varview



Datos obtenido de la base de datos de NCBI

Como dato adicional, un estudio realizado con más de dos mil personas en Costa Rica, encontró que dietas altas en grasas que producen altos niveles de colesterol incrementa el riesgo de ataques cardiacos en presencia de las variaciones APOE-ε2 y APOE-ε4 comparada con el APOE-ε3. (abstract del estudio).

Referencias

https://www.ncbi.nlm.nih.gov/gene/348

https://www.ncbi.nlm.nih.gov/nuccore/NM 001302688.1

https://www.omim.org/entry/107741?search=alzheimer&highlight=alzheimer

http://amigo.geneontology.org/amigo/search/ontology?q=APOE

http://www.uniprot.org/uniprot/P02649

http://www.genecards.org/cgi-bin/carddisp.pl?gene=APOE&keywords=apolipoprotein

https://reactome.org/content/detail/R-HSA-174646

http://www.genome.jp/dbget-bin/www_bget?ko:K04524

https://www.snpedia.com/index.php/APOE

https://www.snpedia.com/index.php/APOE-%CE%B54

https://www.snpedia.com/index.php/Rs429358

https://www.ncbi.nlm.nih.gov/clinvar/?term=APOE%5Bgene%5D

https://www.ncbi.nlm.nih.gov/snp/?term=APOE++rs429358

https://ghr.nlm.nih.gov/gene/APOE#location

https://www.ncbi.nlm.nih.gov/pubmed/18494374?dopt=Abstract

https://www.ebi.ac.uk/Tools/msa/

https://www.ensembl.org/Homo_sapiens/Gene/Splice?db=core;g=ENSG00000130203;r=19:

44905754-44909393